

Majeure Machine Learning

Deep Learning
Introduction

Contenu



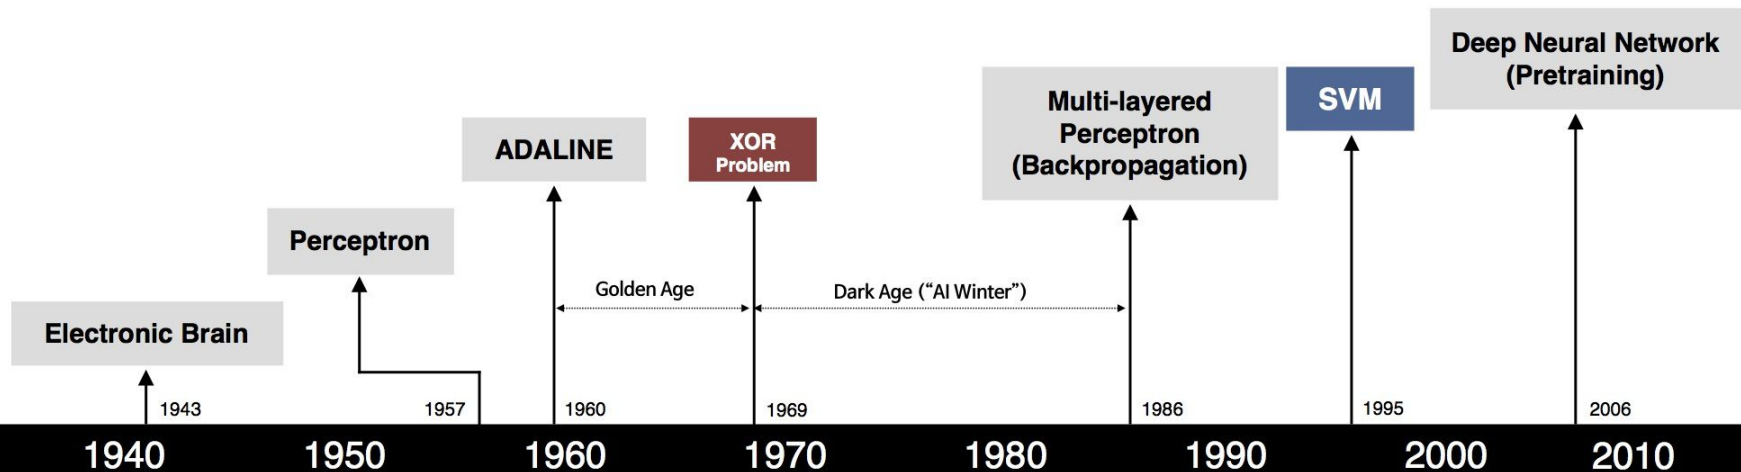
- Principe de Deep Learning
- Réseau de neurones
- Fonctions d'activation
- Backpropagation

Ce que vous devrez savoir faire




- Comprendre ce qu'est le Deep Learning
- Comprendre ce qu'est un neurone artificiel
- Comprendre ce qu'est un réseau de neurones
- Comprendre l'intuition de la Backpropagation

Deep Learning




S. McCulloch – W. Pitts



- Adjustable Weights
- Weights are not Learned



F. Rosenblatt




- Learnable Weights and Threshold



B. Widrow – M. Hoff




M. Minsky – S. Papert



- XOR Problem




D. Rumelhart – G. Hinton – R. Williams



- Solution to nonlinearly separable problems
- Big computation, local optima and overfitting




V. Vapnik – C. Cortes



- Limitations of learning prior knowledge
- Kernel function: Human Intervention



G. Hinton – S. Ruslan



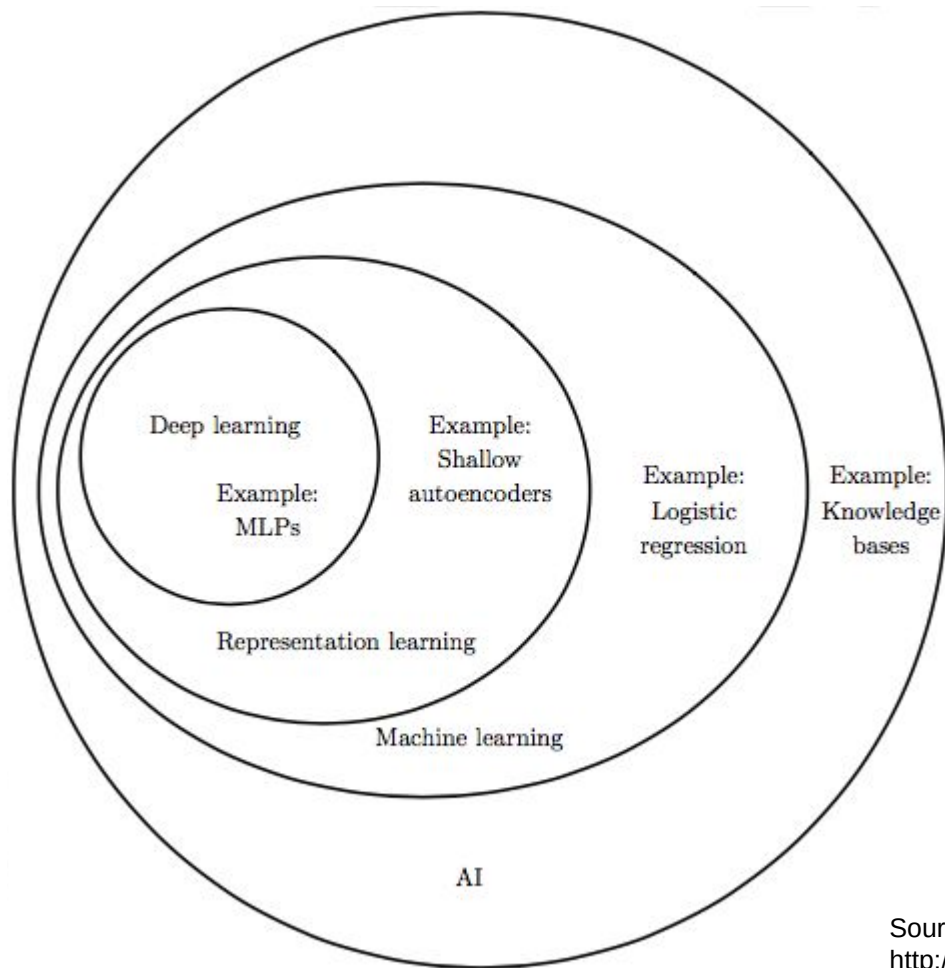
- Hierarchical feature Learning

Définition

“L'apprentissage profond est un ensemble de méthodes d'apprentissage automatique tentant de modéliser avec un haut niveau d'abstraction des données grâce à des architectures articulées de différentes transformations non linéaires.”


Wikipedia

Définition




Définition

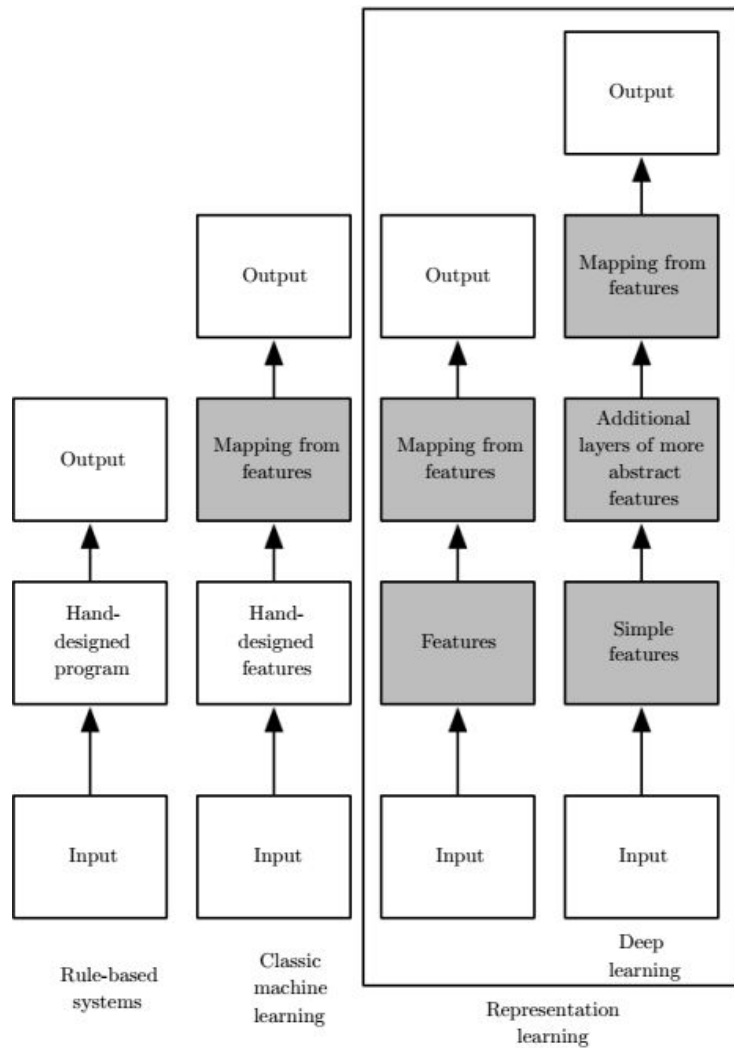
Machine Learning



Deep Learning




Définition




Source :
<http://www.deeplearningbook.org>

Pourquoi un tel essor depuis 2010




Le deep learning aujourd'hui



Les réseaux de neurones

Une inspiration biologique



Le neurone artificiel (Perceptron)


Pré-activation :

$$a(x) = b + \sum_i w_i x_i$$


Activation (output) :

$$h(x) = g(a(x)) = g(b + \sum_i w_i x_i)$$


- **w** => poids
- **b** => biais
- **g(.)** => fonction d'activation




Feed Forward Neural Network (Multi Layer Perceptron)




Feed Forward Neural Network



Feed Forward Neural Network




Intuition de capacité



Démo - Playground

DEMO

Fonctions d'activation - Couches cachées




- Très utilisé jusqu'à il y a quelques années
- Problème : Gradient Vanishing

- Très utilisé dans les RNNs
- Même problème que la Sigmoid

- Référence actuelle pour les FeedForwards
- Sparse (peut être égale à 0) => bien pour l'optimisation et le stockage
- Plus de problème de Gradient Vanishing sur la partie positive
- Problème de "Dying"


Fonctions d'activation (Régression) - Output



$$o(x) = b + \sum_i w_i h_i^2$$

Fonctions d'activation (Classification) - Output


Binaire



Sigmoid :

$$\sigma(x) = \frac{1}{1+e^{-x}}$$

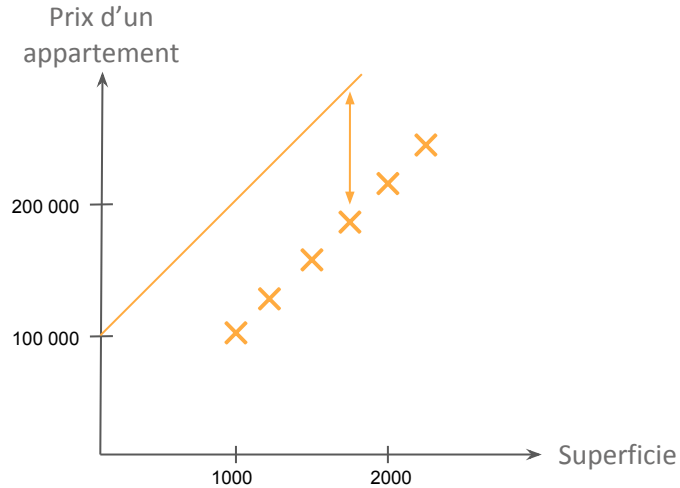
Multi-class



Softmax :

$$p(y = j | \mathbf{x}) = \frac{e^{(\mathbf{w}_j^T \mathbf{x} + b_j)}}{\sum_{k \in K} e^{(\mathbf{w}_k^T \mathbf{x} + b_k)}}$$

Cost Function - Rappel



$$J(\theta) = 1/N \sum_{n=1}^N (\hat{y}(x_n, \theta) - y(x_n))^2$$

=> **Objectif : Minimiser la Cost function**

Fonction Coût : Régression

$$J(\theta) = 1/N \sum_{n=1}^N (\hat{y}(x_n, \theta) - y(x_n))^2$$

Fonction Coût : Classification

Cross Entropy :

$$C(\theta) = \sum_{i=1}^n y^i \log(\hat{y}^i) + (1 - y^i) \log(1 - \hat{y}^i)$$

=> Objectif : Minimiser la Cost function

Descente de gradients - rappel

$$J(\theta) = 1/N \sum_{n=1}^N (\hat{y}(x_n, \theta) - y(x_n))^2$$



Dérivée partielle : $\frac{\partial J(\theta)}{\partial \theta_1} = 1/N \sum_{n=1}^N (\hat{y}(x_n, \theta) - y(x_n)) x_n$

Pour i allant de 1 à nombre_choisi :

$$\theta_1 = \theta_1 - \alpha \frac{\partial J(\theta)}{\partial \theta_1}$$


$J(\theta_1)$

Avec $\alpha > 0$, le pas d'avancement





$\theta_1 = 5$
Dérivée partielle = 3
 $\Rightarrow \theta_1 = 5 - 1 \cdot 3 = 2$

$\theta_1 = 2$
Dérivée partielle = -1
 $\Rightarrow \theta_1 = 2 - 1 \cdot (-1) = 2 + 1 = 3$



Descente de gradients - problématique des réseaux de neurones





$$\hat{y}(x) - y(x)$$

=> Comment calculer les erreurs des couches précédentes ?

Backpropagation

FP





Fin du chapitre 5.1